

Tecnológico de Monterrey

Escuela de Ingeniería y Ciencias

Analizador Léxico para el Lenguaje Triton GPU Kernel

Implementación con UNIX-lex (flex) y C++

TC3002B — Computer Science Advanced Applications Development

Módulo 3: Compilers — Step I: Lexical Analysis Phase

Autores:	Jose Maria Soto Valenzuela — A01254831
	Cesal Alan Silva Ramos — A0XXXXXXX
	Julian Espinoza — A0XXXXXXX
	Fong — A0XXXXXXX
Profesor:	Dr. Salvador Hinojosa
Campus:	Guadalajara
Fecha:	Abril 2026

Tabla de Contenidos

1. [Introducción](#)

- 1.1 [Resumen](#)
- 1.2 [Notación](#)

2. [Análisis](#)

- 2.1 [Descripción Informal de los Componentes Léxicos](#)
- 2.2 [Identificación de Tokens y Token IDs](#)
- 2.3 [Especificación Formal: Expresiones Regulares](#)
- 2.4 [Descripción y Justificación de Mensajes de Error](#)

3. [Diseño](#)

- 3.1 [Autómatas Finitos Deterministas](#)
- 3.2 [Tablas de Transición](#)
- 3.3 [Gestión de la Tabla de Símbolos](#)

4. [Implementación](#)

5. [Verificación y Validación](#)

6. [Plan de Trabajo](#)

7. [Referencias](#)

1. Introducción

1.1 Resumen

Este documento presenta el análisis, diseño, implementación y verificación de un **analizador léxico** (scanner) para un subconjunto del lenguaje **Triton GPU Kernel**. Triton es un lenguaje de dominio específico (DSL) de tipo Python, desarrollado por OpenAI, que permite escribir kernels de GPU de alto rendimiento utilizando sintaxis familiar y operaciones especializadas sobre tensores [2].

El scanner fue implementado utilizando la herramienta **flex** (Fast Lexical Analyzer Generator) con código de usuario en **C++**, conforme a los lineamientos del curso TC3002B. Su función principal es leer un archivo fuente de Triton carácter por carácter y producir dos salidas:

1. **Secuencia de tokens:** Lista ordenada de todos los tokens reconocidos, cada uno con su tipo (Token ID), lexema y número de línea.
2. **Tabla de símbolos:** Registro de identificadores, literales numéricos, literales de cadena y errores léxicos encontrados durante el análisis.

El documento está organizado siguiendo el estándar IEEE-830 [5] y cubre las fases del proceso de desarrollo: análisis de requerimientos (Sección 2), diseño del sistema (Sección 3), implementación (Sección 4), y verificación y validación (Sección 5).

1.2 Notación

A lo largo de este documento se utilizan los siguientes formalismos y convenciones:

Autómatas Finitos Deterministas (AFD)

Un autómata finito determinista es un modelo matemático que lee una cadena de entrada símbolo por símbolo y decide si la acepta o rechaza. Se define formalmente como una 5-tupla $M = (Q, \Sigma, \delta, q_0, F)$ donde:

- Q es un conjunto finito de estados.
- Σ es el alfabeto de entrada (conjunto finito de símbolos).
- $\delta: Q \times \Sigma \rightarrow Q$ es la función de transición, que dado un estado actual y un símbolo de entrada, produce exactamente un estado siguiente.
- $q_0 \in Q$ es el estado inicial.
- $F \subseteq Q$ es el conjunto de estados de aceptación.

La propiedad fundamental del AFD es que es **determinista**: para cada par (estado, símbolo) existe exactamente una transición, lo que garantiza una ejecución eficiente en tiempo $O(n)$ donde n es la longitud de la entrada [1].

Expresiones Regulares

Las expresiones regulares son una notación algebraica para describir conjuntos de cadenas (lenguajes regulares). Las operaciones utilizadas en este documento son:

Operación	Notación	Significado
Concatenación	<code>ab</code>	La cadena <code>a</code> seguida de <code>b</code>
Unión	<code>a b</code>	La cadena <code>a</code> o la cadena <code>b</code>
Cerradura de Kleene	<code>a*</code>	Cero o más repeticiones de <code>a</code>
Cerradura positiva	<code>a+</code>	Una o más repeticiones de <code>a</code>
Opcional	<code>a?</code>	Cero o una ocurrencia de <code>a</code>
Clase de caracteres	<code>[a-z]</code>	Cualquier carácter en el rango indicado
Negación de clase	<code>[^a]</code>	Cualquier carácter excepto los indicados

Las expresiones regulares y los autómatas finitos son formalismos equivalentes en poder expresivo: todo lenguaje que se puede describir con una expresión regular puede ser reconocido por un AFD, y viceversa [1].

Tablas de Transición

Una tabla de transición es la representación tabular de la función δ de un AFD. Las filas corresponden a los estados, las columnas a clases de símbolos de entrada, y cada celda indica el estado destino. Se utiliza la convención:

- $\rightarrow$ marca el estado inicial
- $*$ marca los estados de aceptación

Justificación del modelo

Se utiliza el modelo de **AFD** para el análisis y diseño porque:

1. Es el modelo estándar para la fase de análisis léxico en compiladores [1].
2. Garantiza reconocimiento en tiempo lineal $O(n)$.
3. Existe correspondencia directa entre las expresiones regulares (especificación) y los AFD (implementación).
4. La herramienta flex convierte internamente las expresiones regulares a AFD optimizados.

Justificación de la herramienta

Se utiliza **flex** como herramienta de implementación porque:

1. Genera automáticamente un scanner en C/C++ a partir de expresiones regulares.

2. Implementa internamente la conversión de expresiones regulares a AFN (construcción de Thompson), luego a AFD (construcción de subconjuntos), y finalmente minimiza el AFD (algoritmo de Hopcroft) [1].
3. Es la herramienta estándar de la industria para análisis léxico [4].
4. Permite una correspondencia directa entre la especificación formal y la implementación, facilitando la trazabilidad.

Justificación del lenguaje de programación

Se utiliza **C++** como lenguaje para el código de usuario dentro del archivo flex porque:

1. Flex genera código compatible con C/C++.
2. C++ ofrece estructuras de datos dinámicas (`vector` , `string`) que simplifican la gestión de la tabla de símbolos y la lista de tokens.
3. C++ proporciona `iostream` para separar la salida estándar (`cout`) de la salida de errores (`cerr`).

2. Análisis

Esta sección describe **qué** debe hacer el analizador léxico: los componentes léxicos del lenguaje Triton, su especificación formal, y los errores que debe detectar.

2.1 Descripción Informal de los Componentes Léxicos

El subconjunto del lenguaje Triton que el scanner debe reconocer se compone de las siguientes categorías:

1. **Palabras reservadas (Keywords):** 18 palabras con significado especial que no pueden usarse como identificadores.
2. **Identificadores (NAME):** Nombres definidos por el usuario para variables, funciones, etc.
3. **Literales numéricos (NUMBER):** Valores enteros y de punto flotante.
4. **Literales de cadena (STRING):** Secuencias de caracteres delimitadas por comillas dobles.
5. **Operadores:** 18 símbolos para operaciones aritméticas, lógicas, de comparación y asignación.
6. **Delimitadores:** 17 símbolos de puntuación y agrupación.
7. **Indentación:** Tokens de estructura (NEWLINE, INDENT, DEDENT).
8. **Comentarios:** Texto iniciado con `#` , consumido sin generar token.
9. **Espacios en blanco:** Espacios y tabs, consumidos sin generar token.

2.2 Identificación de Tokens y Token IDs

Los Token IDs se agrupan por rangos para mantener orden:

- **100–117** → Keywords (18 tokens)
- **200–202** → Identificadores y literales (3 tokens)
- **300–317** → Operadores (18 tokens)

- **400–416** → Delimitadores (17 tokens)
- **500–502** → Indentación/estructura (3 tokens)
- **999** → Error

2.2.1 Keywords (Palabras Reservadas)

Son palabras con significado especial en el lenguaje. No pueden usarse como identificadores.

#	Token ID	Nombre del Token	Lexema	Descripción
1	100	TOK_DEF	def	Definición de función
2	101	TOK_RETURN	return	Retorno de función
3	102	TOK_IF	if	Condicional
4	103	TOK_ELSE	else	Rama alternativa
5	104	TOK_ELIF	elif	Rama condicional alternativa
6	105	TOK_FOR	for	Ciclo for
7	106	TOK_WHILE	while	Ciclo while
8	107	TOK_IN	in	Pertenencia / iteración
9	108	TOK_IS	is	Identidad de objeto
10	109	TOK_AND	and	Operador lógico AND
11	110	TOK_OR	or	Operador lógico OR
12	111	TOK_NOT	not	Operador lógico NOT
13	112	TOK_TRUE	True	Literal booleano verdadero
14	113	TOK_FALSE	False	Literal booleano falso
15	114	TOK_NONE	None	Valor nulo
16	115	TOK_PASS	pass	Instrucción vacía
17	116	TOK_BREAK	break	Salir de ciclo
18	117	TOK_CONTINUE	continue	Siguiente iteración de ciclo

Total: 18 keywords

2.2.2 Identificadores y Literales

Tokens cuyo lexema varía (no son cadenas fijas).

#	Token ID	Nombre del Token	Patrón	Descripción
19	200	TOK_NAME	<code>[a-zA-Z_][a-zA-Z0-9_]*</code>	Identificador (variable, función, etc.)
20	201	TOK_NUMBER	<code>[0-9]+(\.[0-9]+)?</code>	Literal numérico (entero o flotante)
21	202	TOK_STRING	<code>`"([^\n])"</code>	<code>\.)*"</code>

Total: 3 tokens

Nota: Las keywords tienen el mismo patrón que NAME. La diferencia se resuelve por prioridad: las reglas de keywords van ANTES que la regla de NAME en el archivo flex.

2.2.3 Operadores

Símbolos que realizan operaciones sobre valores.

#	Token ID	Nombre del Token	Lexema	Descripción
22	300	TOK_PLUS	<code>+</code>	Suma
23	301	TOK_MINUS	<code>-</code>	Resta
24	302	TOK_TIMES	<code>*</code>	Multiplicación
25	303	TOK_DIVIDE	<code>/</code>	División
26	304	TOK_FLOORDIV	<code>//</code>	División entera
27	305	TOK_MOD	<code>%</code>	Módulo (residuo)
28	306	TOK_POWER	<code>**</code>	Potencia
29	307	TOK_LT	<code><</code>	Menor que
30	308	TOK_GT	<code>></code>	Mayor que
31	309	TOK_LE	<code><=</code>	Menor o igual
32	310	TOK_GE	<code>>=</code>	Mayor o igual

#	Token ID	Nombre del Token	Lexema	Descripción
33	311	TOK_EQ	==	Igualdad
34	312	TOK_NE	!=	Desigualdad
35	313	TOK_ASSIGN	=	Asignación
36	314	TOK_PLUSEQ	+=	Asignación con suma
37	315	TOK_MINUSEQ	-=	Asignación con resta
38	316	TOK_TIMESEQ	*=	Asignación con multiplicación
39	317	TOK_DIVEQ	/=	Asignación con división

Total: 18 operadores

Nota importante sobre orden en flex: Los operadores de 2 caracteres (`**` , `//` , `<=` , `>=` , `==` , `!=` , `+=` , `-=` , `*=` , `/=`) deben definirse ANTES que los de 1 carácter para que la regla de **longest match** funcione.

2.2.4 Delimitadores

Símbolos de puntuación y agrupación.

#	Token ID	Nombre del Token	Lexema	Descripción
40	400	TOK_LPAREN	(	Paréntesis izquierdo
41	401	TOK_RPAREN	)	Paréntesis derecho
42	402	TOK_LBRACKET	[	Corchete izquierdo
43	403	TOK_RBRACKET	]	Corchete derecho
44	404	TOK_LBRACE	{	Llave izquierda
45	405	TOK_RBRACE	}	Llave derecha
46	406	TOK_COMMA	,	Coma
47	407	TOK_COLON	:	Dos puntos
48	408	TOK_DOT	.	Punto (acceso a miembro)
49	409	TOK_AT	@	Decorador

#	Token ID	Nombre del Token	Lexema	Descripción
50	410	TOK_ARROW	->	Flecha (anotación de retorno)
51	411	TOK_TILDE	~	Complemento bitwise
52	412	TOK_AMPERSAND	&	AND bitwise
53	413	TOK_PIPE		OR bitwise
54	414	TOK_CARET	^	XOR bitwise
55	415	TOK_LSHIFT	<<	Shift izquierdo
56	416	TOK_RSHIFT	>>	Shift derecho

Total: 17 delimitadores

Nota: -> , << y >> son de 2 caracteres, deben ir antes que > , < y - en flex.

2.2.5 Indentación y Estructura

Tokens que controlan la estructura del programa.

#	Token ID	Nombre del Token	Lexema	Descripción
57	500	TOK_NEWLINE	\n	Salto de línea
58	501	TOK_INDENT	(lógico)	Aumento de nivel de indentación
59	502	TOK_DEDENT	(lógico)	Reducción de nivel de indentación

Total: 3 tokens

Nota: INDENT y DEDENT son tokens lógicos. Se generan comparando el número de espacios al inicio de cada línea con una pila de niveles de indentación. Para esta implementación básica, NEWLINE se emite directamente; INDENT/DEDENT se pueden manejar de forma simplificada.

2.2.6 Error

#	Token ID	Nombre del Token	Descripción
60	999	TOK_ERROR	Carácter o secuencia no reconocida

2.2.7 Elementos que NO generan token

Estos se consumen pero no producen salida:

Elemento	Patrón	Acción
Comentarios	<code>#[\n]*</code>	Se ignora (consume hasta fin de línea)
Espacios/Tabs	<code>[\t]+</code>	Se ignora

Resumen por categoría

Tabla 9: Resumen de tokens por categoría

Categoría	Rango de IDs	Cantidad
Keywords	100–117	18
Identificadores/Literales	200–202	3
Operadores	300–317	18
Delimitadores	400–416	17
Indentación	500–502	3
Error	999	1
Total		60
Sin token (comentarios, espacios)	—	2

2.3 Especificación Formal: Expresiones Regulares

A continuación se presenta la expresión regular formal para cada categoría de token, junto con una explicación de su estructura y ejemplos de cadenas que acepta y rechaza. Estas expresiones regulares son las que se implementarán directamente en el archivo flex del scanner.

2.3.1 Palabras Reservadas (Keywords)

Las keywords son cadenas literales fijas. Su expresión regular es simplemente la cadena exacta:

Tabla 10: Expresiones regulares para keywords

Token	Expresión Regular	Explicación
TOK_DEF	<code>"def"</code>	Cadena literal exacta <code>def</code>
TOK_RETURN	<code>"return"</code>	Cadena literal exacta <code>return</code>
TOK_IF	<code>"if"</code>	Cadena literal exacta <code>if</code>

Token	Expresión Regular	Explicación
TOK_ELSE	"else"	Cadena literal exacta <code>else</code>
TOK_ELIF	"elif"	Cadena literal exacta <code>elif</code>
TOK_FOR	"for"	Cadena literal exacta <code>for</code>
TOK_WHILE	"while"	Cadena literal exacta <code>while</code>
TOK_IN	"in"	Cadena literal exacta <code>in</code>
TOK_IS	"is"	Cadena literal exacta <code>is</code>
TOK_AND	"and"	Cadena literal exacta <code>and</code>
TOK_OR	"or"	Cadena literal exacta <code>or</code>
TOK_NOT	"not"	Cadena literal exacta <code>not</code>
TOK_TRUE	"True"	Cadena literal exacta <code>True</code> (mayúscula inicial)
TOK_FALSE	"False"	Cadena literal exacta <code>False</code> (mayúscula inicial)
TOK_NONE	"None"	Cadena literal exacta <code>None</code> (mayúscula inicial)
TOK_PASS	"pass"	Cadena literal exacta <code>pass</code>
TOK_BREAK	"break"	Cadena literal exacta <code>break</code>
TOK_CONTINUE	"continue"	Cadena literal exacta <code>continue</code>

Justificación: En flex, las comillas dobles alrededor de la cadena indican que se toma como texto literal, sin interpretar caracteres especiales. Las keywords deben definirse **antes** que la regla de identificadores en el archivo flex para que la regla de *first match* les dé prioridad cuando la longitud coincida.

Nota: `True` , `False` y `None` llevan mayúscula inicial porque así se definen en Python/Triton, a diferencia de las demás keywords que son minúsculas.

2.3.2 Identificadores (NAME)

```
[a-zA-Z_] [a-zA-Z0-9_]*
```

Desglose carácter por carácter:

Parte	Significado
[a-zA-Z_]	El primer carácter debe ser una letra minúscula (a-z), mayúscula (A-Z), o guión bajo (_)
[a-zA-Z0-9_]	Los caracteres siguientes pueden ser letras, dígitos (0-9), o guión bajo
*	Cero o más repeticiones del grupo anterior

Ejemplos:

Cadena	¿Acepta?	Por qué
x	✓	Una letra sola es válida
foo	✓	Tres letras
_temp	✓	Inicia con _
myVar2	✓	Mezcla letras y dígitos (no inicia con dígito)
__init__	✓	Múltiples guiones bajos
add_kernel	✓	Guión bajo en medio
2bad	✗	Inicia con dígito
my-var	✗	Contiene guión (no es _)
if	✓ como regex, pero se clasifica como TOK_IF por <i>first match</i>	

Justificación: Esta regex sigue la convención estándar de identificadores de Python/Triton. La restricción de no iniciar con dígito evita ambigüedad con literales numéricos.

2.3.3 Literales Numéricos (NUMBER)

Se usan dos patrones separados en flex, uno para flotantes y otro para enteros. El patrón de flotante debe ir **antes** que el de entero para que el longest match prefiera 3.14 como un solo token en vez de 3 , . , 14 .

Patrón para flotantes:

```
[0-9]+"."[0-9]+
```

Parte	Significado
[0-9]+	Uno o más dígitos (parte entera, obligatoria)
"."	Punto decimal (literal en flex, entre comillas)
[0-9]+	Uno o más dígitos (parte decimal, obligatoria)

Patrón para enteros:

[0-9]+

Parte	Significado
[0-9]+	Uno o más dígitos

Ejemplos:

Cadena	¿Acepta?	Como qué
0	✓	Entero
42	✓	Entero
1024	✓	Entero
3.14	✓	Flotante
0.5	✓	Flotante
100.0	✓	Flotante
.5	×	No tiene parte entera
3.	×	No tiene parte decimal
3.14.15	×	Se leería como 3.14 + . + 15 (tres tokens)

Justificación: Se requieren dígitos a ambos lados del punto para evitar ambigüedad con el operador punto (.). Esta es la versión estricta recomendada en el documento del profesor.

2.3.4 Literales de Cadena (STRING)

Patrón para cadenas con comillas dobles:

```
\"([^\\"\\n]|\\.)*\"
```

Parte	Significado
\"	Comilla doble de apertura (escapada con \ en flex)
(...)*	Cero o más repeticiones de lo siguiente:
[^\\"\\n]	Cualquier carácter excepto " , \ y \n
	O bien...
\\.	Un \ seguido de cualquier carácter (secuencia de escape)
\"	Comilla doble de cierre

Patrón para cadenas con comillas simples:

```
\'([^\'\\n]|\\.)*\'
```

Mismo patrón pero con comillas simples.

Ejemplos:

Cadena	¿Acepta?	Por qué
"hola"	✓	Cadena simple
"hola mundo"	✓	Cadena con espacio
""	✓	Cadena vacía
"con \"comillas\""	✓	Comillas escapadas dentro
"línea\\n"	✓	Backslash escapado
"sin cierre	×	Falta comilla de cierre → error léxico
"multi\\nlinea"	×	\n literal corta la cadena → error léxico

Justificación: El patrón rechaza saltos de línea (\n) dentro de la cadena. Si se llega al fin de línea sin encontrar la comilla de cierre, el scanner detecta una cadena no terminada y emite un error.

Patrón para cadena no terminada (error):

```
\"[^\"\\n]*$
```

Este patrón captura una comilla de apertura seguida de caracteres que no son comilla ni newline, hasta el fin de línea (`$`). Cuando coincide, se emite un error.

2.3.5 Operadores

Los operadores de **dos caracteres** deben definirse primero en flex para que la regla de *longest match* los prefiera sobre los de un carácter.

Tabla 11: Expresiones regulares para operadores

Operadores de dos caracteres (definir primero en flex):

Token	Expresión Regular	Explicación
TOK_POWER	"**"	Dos asteriscos consecutivos
TOK_FLOORDIV	"//"	Dos slashes consecutivos
TOK_LE	"<="	Menor seguido de igual
TOK_GE	">="	Mayor seguido de igual
TOK_EQ	"=="	Dos signos de igual
TOK_NE	"!="	Exclamación seguida de igual
TOK_PLUSEQ	"+="	Más seguido de igual
TOK_MINUSEQ	"-="	Menos seguido de igual
TOK_TIMESEQ	"*="	Asterisco seguido de igual
TOK_DIVEQ	"/="	Slash seguido de igual

Operadores de un carácter (definir después en flex):

Token	Expresión Regular	Explicación
TOK_PLUS	"+"	Signo más
TOK_MINUS	"-"	Signo menos
TOK_TIMES	"*"	Asterisco
TOK_DIVIDE	"/"	Slash

Token	Expresión Regular	Explicación
TOK_MOD	"%"	Signo de porcentaje
TOK_LT	"<"	Menor que
TOK_GT	">"	Mayor que
TOK_ASSIGN	"="	Signo de igual (asignación)

Justificación del orden: Si "=" estuviera antes que "==", al leer == flex tomaría el primer = como TOK_ASSIGN y el segundo como otro TOK_ASSIGN. Con longest match, si "==" está definido, flex prefiere consumir ambos caracteres como un solo token.

2.3.6 Delimitadores

Tabla 12: Expresiones regulares para delimitadores

Delimitadores de dos caracteres (definir primero):

Token	Expresión Regular	Explicación
TOK_ARROW	"->"	Guión seguido de mayor-que
TOK_LSHIFT	"<<"	Dos signos menor-que
TOK_RSHIFT	">>"	Dos signos mayor-que

Delimitadores de un carácter:

Token	Expresión Regular	Explicación
TOK_LPAREN	"("	Paréntesis izquierdo
TOK_RPAREN	")"	Paréntesis derecho
TOK_LBRACKET	"["	Corchete izquierdo
TOK_RBRACKET	"]"	Corchete derecho
TOK_LBRACE	"{"	Llave izquierda
TOK_RBRACE	"}"	Llave derecha
TOK_COMMA	","	Coma
TOK_COLON	":"	Dos puntos

Token	Expresión Regular	Explicación
TOK_DOT	"."	Punto
TOK_AT	"@"	Arroba (decorador)
TOK_TILDE	"~"	Tilde (complemento bitwise)
TOK_AMPERSAND	"&"	Ampersand (AND bitwise)
TOK_PIPE	" "	Pipe (OR bitwise), escapado con \ en flex
TOK_CARET	"^"	Caret (XOR bitwise)

Justificación: `->` debe ir antes que `-` y `>` por separado. `<<` antes que `<`. `>>` antes que `>`. Todos son cadenas literales fijas.

2.3.7 Indentación y Estructura

Token	Expresión Regular	Explicación
TOK_NEWLINE	\n	Carácter de salto de línea
TOK_INDENT	(lógico)	No tiene regex; se genera por lógica de pila de indentación
TOK_DEDENT	(lógico)	No tiene regex; se genera por lógica de pila de indentación

2.3.8 Comentarios (sin token)

```
#[^\n]*
```

Parte	Significado
#	El carácter # inicia el comentario
[^\n]*	Cero o más caracteres que no sean salto de línea

Se consume la línea completa desde # hasta el fin de línea. **No se genera token;** el scanner simplemente ignora este texto.

2.3.9 Espacios en blanco (sin token)

```
[ \t]+
```

Parte	Significado
[\t]	Un espacio o un tab
+	Uno o más

Se consumen sin generar token.

2.3.10 Carácter no reconocido (error)

.

El punto (.) en flex coincide con **cualquier carácter** que no haya sido capturado por ninguna regla anterior. Como está al final del archivo, solo se activa para caracteres que no pertenecen al alfabeto del lenguaje (como \$, \ , etc.). Genera un token de error.

2.4 Descripción y Justificación de Mensajes de Error

El scanner debe detectar situaciones donde la entrada no corresponde a ningún token válido del lenguaje Triton. A continuación se describen los tipos de errores léxicos que se manejan, el formato de sus mensajes, la justificación de por qué se detectan, y ejemplos concretos.

2.4.1 Tipos de errores léxicos

Tabla 13: Errores léxicos detectados por el scanner

#	Tipo de Error	Patrón que lo detecta	Formato del mensaje
1	Carácter no reconocido	. (regla catch-all al final)	Error lexico: caracter invalido '<char>' en linea <n>
2	Cadena no terminada	\("[^"\n]*\$	Error lexico: cadena no terminada en linea <n>

2.4.2 Error 1: Carácter no reconocido

¿Qué es? Un carácter que no pertenece al alfabeto del lenguaje Triton. No es letra, dígito, operador, delimitador, ni espacio en blanco.

¿Cómo se detecta? La regla . al final del archivo flex coincide con cualquier carácter que no fue capturado por ninguna regla anterior. Como es la última regla, solo se activa para caracteres que no pertenecen al lenguaje.

Ejemplo:

Entrada	Error generado
<code>y = \$5</code>	Error lexico: caracter invalido '\$' en linea 1
<code>x = 10 \ 2</code>	Error lexico: caracter invalido '\' en linea 1
<code>val = 5 ¿ 3</code>	Error lexico: caracter invalido '¿' en linea 1

¿Qué hace el scanner?

1. Imprime el mensaje de error en `stderr` con el carácter y la línea
2. Registra el carácter en la tabla de símbolos con el campo `error` indicando el problema
3. Emite un token `TOK_ERROR` (ID 999)
4. **Continúa** analizando el resto de la entrada (no se detiene)

Justificación: El scanner debe ser robusto: un solo carácter inválido no debe impedir el análisis del resto del archivo. Reportar el error con la línea exacta permite al usuario localizar y corregir el problema.

2.4.3 Error 2: Cadena no terminada

¿Qué es? Una cadena que abre con comilla doble (") pero llega al fin de línea sin la comilla de cierre.

¿Cómo se detecta? El patrón `\"[^\\"\\n]*$` captura una comilla de apertura seguida de caracteres que no son comilla ni newline, y que llega hasta el fin de línea (\$) sin encontrar la comilla de cierre.

Ejemplo:

Entrada	Error generado
<code>msg = "hola</code>	Error lexico: cadena no terminada en linea 1
<code>s = "abc</code>	Error lexico: cadena no terminada en linea 1

¿Qué hace el scanner?

1. Imprime el mensaje de error en `stderr` con la línea
2. Registra la cadena parcial en la tabla de símbolos con `error = "Cadena no terminada: falta comilla de cierre"`
3. Emite un token `TOK_ERROR` (ID 999)
4. Continúa con la siguiente línea

Justificación: En Triton (como en Python), las cadenas de una sola línea no pueden contener saltos de línea literales. Si se llega al fin de línea sin cerrar la comilla, es un error del programador. Reportar la línea exacta facilita la corrección.

2.4.4 Registro de errores en la tabla de símbolos

Cuando se detecta un error, se registra en la tabla de símbolos con la siguiente estructura:

Tabla 14: Formato de registro de errores en la tabla de símbolos

Campo	Valor para carácter inválido	Valor para cadena no terminada
Token	(desconocido)	STRING
Identificador	El carácter inválido (ej: \$)	(literal)
Valor	---	El texto parcial (ej: "hola)
Error	Caracter invalido/no reconocido	Cadena no terminada: falta comilla de cierre

2.4.5 Justificación general del manejo de errores

Cada mensaje de error sigue tres principios de diseño de compiladores [1]:

1. **Especificidad:** Indica exactamente qué tipo de error ocurrió
2. **Localización:** Incluye el número de línea para que el usuario pueda encontrarlo
3. **Continuidad:** El scanner no se detiene ante un error; continúa para reportar todos los errores en una sola ejecución

3. Diseño

Esta sección presenta **cómo** se implementará el scanner. Traduce las especificaciones formales del análisis (sección 2) en autómatas finitos deterministas (AFD), tablas de transición, y estructuras de datos. El objetivo es que este diseño sea suficiente para que cualquier programador pueda implementar el scanner sin información adicional.


3.1 Autómatas Finitos Deterministas

Según la especificación del Lexer.xlsx, los siguientes tokens requieren un autómata con su tabla de transición: identificadores (NAME), números (NUMBER), cadenas (STRING), las keywords `if / else / elif` (combinadas), `while`, y los operadores aritméticos. A continuación se presenta cada AFD con su diagrama, descripción y traza de ejemplo.

3.1.1 AFD para Identificadores (NAME)

Este autómata reconoce identificadores válidos: comienzan con letra o `_`, seguidos de cero o más letras, dígitos o `_`. Una vez reconocido el lexema, se consulta la tabla de keywords; si coincide, se emite el token de keyword correspondiente en lugar de NAME.

Figura 1: AFD para identificadores (NAME)



Estados:

- **q0** — Estado inicial. Espera el primer carácter.
- **q1_acepta** — Estado de aceptación. Se acumulan letras, dígitos y `_`.
- **qErr** — Error: el identificador inició con un dígito.


Traza de ejemplo para `"pid "` (con espacio al final):

Paso	Estado	Carácter	Transición	Acumulado
1	q0	p (letra)	→ q1	"p"
2	q1	i (letra)	→ q1	"pi"
3	q1	d (letra)	→ q1	"pid"
4	q1	(espacio)	→ acepta	Emite NAME "pid"

3.1.2 AFD para Literales Numéricos (NUMBER)

Reconoce enteros (`[0-9]+`) y flotantes (`[0-9]+.[0-9]+`). El estado q2 (tras el punto) no es de aceptación: si no hay dígitos después del punto, el número es inválido y se retrocede.

Figura 2: AFD para números (NUMBER)



Estados:

- **q0** — Estado inicial.
- **q1_entero** — Aceptación. Se han leído uno o más dígitos (entero válido).
- **q2** — No aceptación. Se leyó el punto decimal, se requiere al menos un dígito después.
- **q3_flotante** — Aceptación. Dígitos después del punto (flotante válido).


Traza de ejemplo para "3.14 " :

Paso	Estado	Carácter	Transición	Acumulado
1	q0	3 (dígito)	→ q1	"3"
2	q1	. (punto)	→ q2	"3."
3	q2	1 (dígito)	→ q3	"3.1"
4	q3	4 (dígito)	→ q3	"3.14"
5	q3	(espacio)	→ acepta	Emite NUMBER "3.14"

3.1.3 AFD para Literales de Cadena (STRING)

Reconoce cadenas delimitadas por comillas dobles, con soporte para secuencias de escape (\ " , \\ , etc.). Si se llega a \n o EOF sin cerrar la comilla, se emite un error.

Figura 3: AFD para cadenas (STRING)



Estados:

- **q0** — Estado inicial. Espera la comilla de apertura.
- **q1_leyendo** — Dentro de la cadena. Acepta cualquier carácter excepto " , \ y \n .
- **q2_escape** — Se leyó un \ . El siguiente carácter se toma literalmente (escape).
- **q3_acepta** — Aceptación. Se encontró la comilla de cierre.
- **qErr** — Error. Se llegó a fin de línea sin cerrar la cadena.


Traza de ejemplo para "ho1a" :

Paso	Estado	Carácter	Transición	Acumulado
1	q0	" (comilla)	→ q1	"
2	q1	h (normal)	→ q1	"h
3	q1	o (normal)	→ q1	"ho
4	q1	l (normal)	→ q1	"hol
5	q1	a (normal)	→ q1	"hola
6	q1	" (comilla)	→ q3	Emite STRING "hola"

3.1.4 AFD para `if`, `else`, `elif` (Keywords combinadas)

Este autómata combina el reconocimiento de tres keywords que comparten prefijos comunes. En la práctica, flex maneja esto automáticamente con reglas separadas, pero el AFD combinado demuestra cómo se podrían reconocer en un solo autómata.

Figura 4: AFD combinado para `if`, `else`, `elif`



Descripción:

- Desde q0, al leer `i` se inicia el camino hacia `if`.
- Desde q0, al leer `e` se inicia el camino hacia `else` o `elif`, que se bifurca en q_el.
- Cada keyword se acepta solo si el siguiente carácter **no** es alfanumérico ni `_` (para distinguir `if` de `iffy` por ejemplo).

3.1.5 AFD para `while`

Figura 5: AFD para la keyword `while`




Descripción: Cadena de estados lineal que reconoce `w → h → i → l → e`. Se acepta solo si el siguiente carácter no es alfanumérico (para distinguir `while` de `whileTrue` por ejemplo).

3.1.6 AFD para Operadores Aritméticos

Este autómata reconoce los 7 operadores aritméticos, incluyendo los de dos caracteres (`**` , `//`) que comparten el primer carácter con operadores de uno (`*` , `/`).

Figura 6: AFD para operadores aritméticos



Descripción:

- `+` , `-` y `%` son directos: un carácter → aceptar.
- `*` requiere lookahead: si el siguiente es `*` → POWER (`**`), si no → TIMES (`*`).
- `/` requiere lookahead: si el siguiente es `/` → FLOORDIV (`//`), si no → DIVIDE (`/`).
- Este es el mecanismo de **longest match** que flex implementa automáticamente.

3.2 Tablas de Transición

Las tablas de transición son la representación tabular de cada AFD. Cada fila es un estado, cada columna es una clase de carácter, y cada celda indica el estado destino. → marca el estado inicial, * marca estados de aceptación.

3.2.1 Tabla de transición — Identificadores (NAME)

Tabla 15: Transiciones del AFD para identificadores

Estado	[a-zA-Z_]	[0-9]	otro
→ q0	q1	error	error
*q1	q1	q1	acepta NAME

Acción al aceptar: Buscar el lexema en la tabla de keywords. Si coincide, emitir el token de keyword correspondiente; si no, emitir TOK_NAME.

3.2.2 Tabla de transición — Números (NUMBER)

Tabla 16: Transiciones del AFD para números

Estado	[0-9]	"."	otro
→ q0	q1	error	error
*q1	q1	q2	acepta INTEGER
q2	q3	error	error (retract)
*q3	q3	error	acepta FLOAT

Nota: Si en q2 no llega un dígito, se retrocede y se emite el entero acumulado hasta q1.

3.2.3 Tabla de transición — Cadenas (STRING)

Tabla 17: Transiciones del AFD para cadenas

Estado	"	\	\n / EOF	otro carácter
→ q0	q1	error	error	error
q1	q3 (acepta)	q2	error (cadena no terminada)	q1
q2	q1	q1	q1	q1
*q3	—	—	—	—

Nota: q2 es el estado de escape: cualquier carácter después de \ se acepta y regresa a q1.

3.2.4 Tabla de transición — if, else, elif

Tabla 18: Transiciones del AFD combinado para if/else/elif

Estado	i	f	e	l	s	no alfanum	otro alfanum
→ q0	q_i	—	q_e	—	—	—	—
q_i	—	q_if	—	—	—	—	→ NAME
*q_if	—	—	—	—	—	acepta IF	→ NAME
q_e	—	—	—	q_el	—	—	→ NAME
q_el	q_eli	—	—	—	q_els	—	→ NAME
q_els	—	—	q_else	—	—	—	→ NAME
*q_else	—	—	—	—	—	acepta ELSE	→ NAME
q_eli	—	q_elif	—	—	—	—	→ NAME
*q_elif	—	—	—	—	—	acepta ELIF	→ NAME

Nota: Si en cualquier estado intermedio llega un carácter alfanumérico inesperado, el lexema completo se trata como un identificador (NAME), no como keyword.

3.2.5 Tabla de transición — while

Tabla 19: Transiciones del AFD para while

Estado	w	h	i	l	e	no alfanum	otro alfanum
→ q0	q1	—	—	—	—	—	—
q1	—	q2	—	—	—	→ NAME	→ NAME
q2	—	—	q3	—	—	→ NAME	→ NAME
q3	—	—	—	q4	—	→ NAME	→ NAME
q4	—	—	—	—	q5	→ NAME	→ NAME
*q5	—	—	—	—	—	acepta WHILE	→ NAME

3.2.6 Tabla de transición — Operadores aritméticos

Tabla 20: Transiciones del AFD para operadores aritméticos

Estado	+	-	*	/	%	otro
→ q0	*qPlus	*qMinus	qStar	qSlash	*qMod	—
qStar	acepta TIMES	acepta TIMES	*qPower	acepta TIMES	acepta TIMES	acepta TIMES
*qPower	—	—	—	—	—	acepta POWER
qSlash	acepta DIVIDE	acepta DIVIDE	acepta DIVIDE	*qFloor	acepta DIVIDE	acepta DIVIDE
*qFloor	—	—	—	—	—	acepta FLOORDIV

Nota: qStar y qSlash requieren lookahead de un carácter para decidir entre `* / **` y `/ / //` respectivamente.

3.3 Gestión de la Tabla de Símbolos

3.3.1 Estructura de datos

La tabla de símbolos se implementa como un `vector` dinámico de registros (structs) en C++. Cada registro almacena:

Tabla 21: Estructura de un registro en la tabla de símbolos

Campo	Tipo C++	Descripción	Ejemplo
token	string	Tipo de token	"NAME", "NUMBER", "STRING"
identifier	string	El lexema	"x", "(literal)"
value	string	Valor asociado	"____", "10", "3.14", "\"hola\""
error	string	Mensaje de error o "____"	"____", "Cadena no terminada"

Justificación del uso de `vector` : A diferencia de un arreglo estático de tamaño fijo, el `vector` de C++ crece dinámicamente según se necesite, evitando la limitación de un `MAX_SYMBOLS` arbitrario.

3.3.2 Algoritmo de inserción

```
PROCEDIMIENTO InsertarSimbolo(token, identificador, valor, error):
    PARA CADA entrada EN tabla_de_simbolos:
        SI entrada.identificador = identificador
```

```

        Y entrada.token = token:
        RETORNAR    // Ya existe, no duplicar
    CREAR nuevo_registro CON (token, identificador, valor, error)
    AGREGAR nuevo_registro A tabla_de_simbolos

```

Justificación: La búsqueda lineal para evitar duplicados es suficiente para programas de tamaño moderado. Para programas muy grandes, se podría usar un `unordered_map` (tabla hash), pero la búsqueda lineal es más simple y trazable al diseño.

3.3.3 Qué tokens se registran en la tabla de símbolos

Token	¿Se registra?	Campos
TOK_NAME	Sí	token= "NAME" , identifier=lexema, value= "----" , error= "----"
TOK_NUMBER	Sí	token= "NUMBER" , identifier= "(literal)" , value=lexema, error= "----"
TOK_STRING	Sí	token= "STRING" , identifier= "(literal)" , value=lexema, error= "----"
TOK_ERROR	Sí	token=tipo de error, identifier=lexema, value= "----" , error=mensaje
Keywords, operadores, delimitadores	No	Solo se emiten como tokens en la secuencia

3.3.4 Ejemplo de tabla de símbolos

Para el código:

```

x = 10
msg = "hola"
z = 3.14

```

Tabla 22: Ejemplo de tabla de símbolos generada

Token	Identificador	Valor	Error
NAME	x	—	—
NUMBER	(literal)	10	—

Token	Identificador	Valor	Error
NAME	msg	—	—
STRING	(literal)	“hola”	—
NAME	z	—	—
NUMBER	(literal)	3.14	—

3.3.5 Trazabilidad al análisis

Requerimiento del análisis (Sección 2)	Componente del diseño (Sección 3)
2.2 — Token IDs definidos	Cada AFD emite el Token ID correcto al aceptar
2.3 — Regex de identificadores	AFD 3.1.1 + Tabla 15
2.3 — Regex de números	AFD 3.1.2 + Tabla 16
2.3 — Regex de cadenas	AFD 3.1.3 + Tabla 17
2.3 — Regex de keywords if/else/elif	AFD 3.1.4 + Tabla 18
2.3 — Regex de keyword while	AFD 3.1.5 + Tabla 19
2.3 — Regex de operadores aritméticos	AFD 3.1.6 + Tabla 20
2.4 — Error de carácter inválido	Regla catch-all . emite TOK_ERROR
2.4 — Error de cadena no terminada	Estado qErr en AFD 3.1.3

4. Implementación

4.1 Sección de Definiciones

POR COMPLETAR

4.2 Sección de Reglas

POR COMPLETAR

4.3 Sección de Código de Usuario

POR COMPLETAR

4.4 Compilación y Ejecución

POR COMPLETAR

5. Verificación y Validación

5.1 Modelo de Pruebas

POR COMPLETAR

5.2 Casos de Prueba

POR COMPLETAR

5.3 Resultados

POR COMPLETAR

6. Plan de Trabajo

POR COMPLETAR

7. Referencias

- [1] Alfred V. Aho, Monica S. Lam, Ravi Sethi, and Jeffrey D. Ullman, *Compilers: Principles, Techniques, and Tools*, 2nd edition (Pearson/Addison-Wesley, 2007), 109–189.
- [2] Philippe Tillet, H. T. Kung, and David Cox, "Triton: An Intermediate Language and Compiler for Tiled Neural Network Computations," *Proceedings of the 3rd ACM SIGPLAN International Workshop on Machine Learning and Programming Languages*, (June 2019): 10–19.
- [3] Ian Sommerville, *Software Engineering*, 9th edition (Addison-Wesley, 2011), 426.
- [4] Vern Paxson, *Flex — Fast Lexical Analyzer Generator*, accessed April 2026; available from <https://github.com/westes/flex>; Internet.
- [5] IEEE, *IEEE Std 830-1998: IEEE Recommended Practice for Software Requirements Specifications*, (IEEE, 1998).
- [6] S. Hinojosa, Class Lecture, Topic: "Lexical Analysis." TC3002B, School of Engineering and Science, ITESM, Guadalajara, Jal., April, 2026.
- [7] OpenAI, *Triton Language and Compiler Documentation*, accessed April 2026; available from <https://triton-lang.org/>; Internet.